

■ ARCHITECTURE MCTN

Multi-scale Convolutional Transformer Network

Démosaïquage d'images hyperspectrales MSFA 4×4

Paramètres	616,064
Performance	PSNR: 37.73 dB SSIM: 0.994
Input/Output	[16, 512, 512] → [16, 512, 512]
Bandes spectrales	16 bandes (400-700 nm)

■ FLUX DE L'ARCHITECTURE

BLOC	COMPOSANTS	DIMENSIONS	FONCTION
■ INPUT	Image Mosaïque MSFA 4×4	[1, 16, 512, 512]	Image brute du capteur 16 bandes entrelacées
■ DÉBRUITAGE	Conv 3×3 (16→64) Conv 3×3 (64→16) $x_{clean} = x - noise$	[1, 16, 512, 512]	Suppression du bruit du capteur MSFA
■■ WHITE BALANCE	Conv 7×7 bilinéaire Grouped (16 groupes) Poids fixes	[1, 16, 512, 512] → WB_norelu	Interpolation initiale de référence (Skip connection)
■ POS2WEIGHT	MLP: (x,y) → poids Linear(2→128→400) Conv adaptative 5×5	[1, 16, 512, 512] → Raw_conv	Poids adaptatifs par position spatiale Pattern MSFA 4×4

■ ATTENTION	Shuffle Down (4×) Multi-head (4 têtes) Shuffle Up (4×)	[1, 16, 512, 512] via [256, 128, 128]	Capture dépendances globales Résolution réduite
■ FEATURES	Conv 3×3 (16→64) 2× Conv_attention_Block Conv 3×3 (64→16)	[1, 64, 512, 512] → [1, 16, 512, 512]	Extraction features hiérarchiques Bas + Haut niveau
■ FUSION	HR_4x + WB_norelu Connexion résiduelle	[1, 16, 512, 512]	Combine interpolation + features profondes
■ OUTPUT	Image Hyperspectrale 16 bandes complètes	[1, 16, 512, 512]	Résultat final démosaïqué

■ COMPOSANTS DÉTAILLÉS

1. MALayer (Multi-head Attention Layer)

Étape	Opération	Dimension	Description
1	Shuffle Down (4×)	[B, C×16, H/4, W/4]	Réduction résolution spatiale
2	Linear Projection	[B, (H/4)×(W/4), C]	Projection vers espace attention
3	Multi-head Attention	4 têtes	Self-attention avec 4 représentations
4	FC Layers	[B, C×16, 1, 1]	Génération carte attention
5	Multiplication	[B, C×16, H/4, W/4]	Application de l'attention
6	Shuffle Up (4×)	[B, C, H, W]	Restauration résolution

2. Pos2Weight (Reconstruction Adaptative)

Étape	Opération	Dimension	Rôle
Input	Position (x, y)	[H×W, 2]	Coordonnées normalisées
MLP Layer 1	Linear(2 → 128) + ReLU	[H×W, 128]	Expansion features
MLP Layer 2	Linear(128 → 400)	[H×W, 400]	Génération poids (5×5×16)
Reshape	View([H, W, 5, 5, 16])	[H, W, 5, 5, 16]	Structure convolution
Application	Convolution locale	[B, 16, H, W]	Chaque pixel = poids uniques

3. Conv_attention_Block (×2 en série)

Composant	Configuration	Sortie
Conv2d #1	kernel=3×3, in=64, out=64	[B, 64, H, W]

LeakyReLU	negative_slope=0.2	[B, 64, H, W]
Conv2d #2	kernel=3×3, in=64, out=64	[B, 64, H, W]
LeakyReLU	negative_slope=0.2	[B, 64, H, W]
Conv2d #3	kernel=3×3, in=64, out=64	[B, 64, H, W]
MALayer	Multi-head Attention	[B, 64, H, W]
Résiduelle	output = output + input	[B, 64, H, W]
LeakyReLU	negative_slope=0.2	[B, 64, H, W]

■ CONCEPTS CLÉS

Concept	Description	Avantage
Double Branche	WB_Conv (rapide) + CNN profond (précis) Fusion finale par addition	Stabilité + Précision Gradient flow amélioré
Attention Multi-échelle	Résolution 512×512 → 128×128 → 512×512 Capture contexte global à coût réduit	Dépendances longue distance Complexité O(n/16)
Poids Adaptatifs	Chaque position (x,y) a ses propres poids w(x,y) au lieu de w fixe	Adaptation pattern MSFA 4×4 Flexibilité maximale
Connexions Résiduelles	Skip connections multiples Output = Features + Input	Apprentissage facilité Évite gradient vanishing
Débruitage Intégré	Estimation et soustraction du bruit $x_{clean} = x - estimated_noise$	Robustesse au bruit capteur Pré-traitement automatique

■ PERFORMANCE ET COMPARAISON

Méthode	PSNR (dB)	SSIM	Paramètres	Adaptatif	Attention	Évaluation
Bilinéaire simple	~25	~0.85	0	■	■	■
CNN classique	~32	~0.92	~300K	■	■	■■
ResNet profond	~35	~0.95	~500K	■■	■	■■■
MCTN (Notre modèle)	37.73	0.994	616K	■	■	■■■■

■ RÉPARTITION DES PARAMÈTRES

Composant	Paramètres	Pourcentage	Entraînable
Denoising (Conv 3×3)	9,216 + 9,216	3.0%	■
WB_Conv (7×7 bilinéaire)	784	0.1%	■ Fixe
Front Conv Input (3×3)	9,216	1.5%	■
Branch Front (MALayer)	~85,000	13.8%	■
Conv_attention_Block × 2	~280,000	45.5%	■
Branch Back (3×3)	1,024	0.2%	■
Pos2Weight (MLP)	51,600	8.4%	■
Autres (bias, etc.)	~170,000	27.5%	■
TOTAL	616,064	100%	99.9%

■ POINTS CLÉS À RETENIR

- **Architecture hybride** : Combine CNN classique + Attention multi-têtes (Vision Transformer)
- **Adaptatif au MSFA** : Pos2Weight génère des poids uniques pour chaque position spatiale
- **Multi-échelle** : Traite l'information à résolution complète ET réduite (1/4)
- **Connexions résiduelles** : Double branche (WB_Conv + CNN profond) pour stabilité
- **Débruitage intégré** : Gère automatiquement le bruit du capteur MSFA
- **Performance SOTA** : 37.73 dB (State-of-the-Art pour démosaïquage 16 bandes)